

Analiza wrażliwości warstwowej na kwantyzację wag w architekturach CNN

Julia Mucha, Patrycja Górka

17 czerwca 2026 r.

1 Teoria i wstęp do problematyki optymalizacji

1.1 Problem reprezentacji danych w systemach Edge AI i FPGA

Współczesne systemy oparte na sieciach neuronowych projektowane są zazwyczaj w środowiskach takich jak TensorFlow lub PyTorch, gdzie operacje zmiennoprzecinkowe odbywają się w standardzie FP32. Standard ten oferuje wysoką precyzję, ale jest niezwykle kosztowny pod kątem zasobów obliczeniowych i energetycznych. W procesie wdrażania modeli na układy programowalne FPGA (Field Programmable Gate Array), konieczne jest przejście na arytmetykę stałoprzecinkową (*fixed-point*). Przejście to nie jest procesem bezstratnym – stanowi ono źródło tzw. degradacji sygnału.

W architekturach FPGA, bloki operacyjne (DSP – *Digital Signal Processing*) są optymalizowane pod kątem szybkiego przetwarzania liczb całkowitych lub stałoprzecinkowych. Zastosowanie formatu `ap_fixed` pozwala na zdefiniowanie precyzyjnej liczby bitów całkowitych oraz ułamkowych. Wyzwanie polega na tym, że ograniczona liczba bitów powoduje błędy kwantyzacji (zaokrąglenia), które podczas propagacji przez setki warstw sieci neuronowej mogą prowadzić do zjawiska „dryftu” predykcji, a w skrajnych przypadkach – do całkowitej utraty zdolności modelu do poprawnej klasyfikacji. Zrozumienie, w którym miejscu sieci ten szum kwantyzacyjny staje się krytyczny, jest kluczowe dla projektowania wydajnych akceleratorów AI.

1.2 Uzasadnienie wyboru zbioru danych CIFAR-10

W projekcie zrezygnowano z wykorzystania zbioru MNIST na rzecz CIFAR-10. Decyzja ta podyktowana była koniecznością przeprowadzenia badań na architekturze o wyższym stopniu złożoności informacyjnej. Podczas gdy MNIST zawiera proste, monochromatyczne obrazy cyfr na jednolitym tle, CIFAR-10 składa się z kolorowych, 32-pikselowych obrazów o dużej wariancji kształtów i tekstur (takich jak samochody, zwierzęta czy samoloty).

Wybór CIFAR-10 sprawia, że każda waga w modelu musi reprezentować znacznie bardziej złożoną cechę wizualną. W takim modelu, błędy kwantyzacji w warstwach spłotowych (wcześniejszych) mają znacznie poważniejsze konsekwencje, gdyż uniemożliwiają poprawne rozpoznanie detali. Z perspektywy inżynierskiej, CIFAR-10 lepiej symuluje wyzwania, przed jakimi stają systemy autonomiczne czy mobilne, gdzie model musi operować w warunkach wysokiego szumu wizualnego.

1.3 Podstawy kwantyzacji (Matematyczne ujęcie `quantize_numpy`)

Proces kwantyzacji wag w prezentowanym modelu został zaimplementowany poprzez funkcję `quantize_numpy`, która emuluje zachowanie sprzętowych jednostek logicznych. Proces ten dzieli się na trzy matematyczne etapy:

1. **Skalowanie i dyskretyzacja:** Proces kwantyzacji rozpoczyna się od wyznaczenia rozdzielczości (kroku kwantyzacji), określonej jako:

$$\Delta = 2^{-\text{frac_bits}}$$

Każda waga modelu w jest skalowana do wartości całkowitej:

$$w_q = \text{round}\left(\frac{w}{\Delta}\right) \cdot \Delta$$

Operacja ta pozwala na przypisanie wartości wag do ograniczonego zbioru stanów, co jest bezpośrednim odzwierciedleniem fizycznej reprezentacji wartości w rejestrach układu FPGA.

2. **Saturacja (Clipping):** Ze względu na ograniczoną liczbę bitów części całkowitej (`int_bits`), konieczne jest zastosowanie mechanizmu saturacji. Wartości wykraczające poza zakres $[\text{min}, \text{max}]$ (wynikający z zapisu dopełnienia do dwóch - U2) są przycinane do wartości granicznych. Jest to krytyczny element symulacji, gdyż w rzeczywistym układzie FPGA przepełnienie arytmetyczne bez odpowiedniej saturacji mogłoby prowadzić do wystąpienia wartości całkowicie błędnych (tzw. *wrap-around*), które w sieciach neuronowych są destrukcyjne.
3. **Format `ap_fixed<bits, int_bits>`:** Użycie tego formatu pozwala na precyzyjne sterowanie zasobami. Zastosowanie większej liczby bitów ułamkowych zwiększa precyzję, ale wymaga szerszych rejestrów, co zwiększa zużycie pamięci BRAM oraz powierzchni logicznej LUT. Wybór odpowiedniej konfiguracji jest zatem kompromisem między dokładnością modelu a kosztem sprzętowym (*Area-Accuracy-Power trade-off*).

1.4 Architektura modelu i charakterystyka warstw

Model zaprojektowany na potrzeby niniejszego badania stanowi zoptymalizowaną strukturę typu CNN, ukierunkowaną na balans między efektywnością obliczeniową a zdolnością ekstrakcji cech. Architektura ta składa się z sekwencji bloków przetwarzania spłotowego oraz sekcji klasyfikacyjnej.

1.4.1 Bloki spłotowe (Feature Extraction)

- **Warstwa `conv_0` (Input Layer):** Pierwsza warstwa spłotowa operuje bezpośrednio na danych wejściowych CIFAR-10 ($32 \times 32 \times 3$). Zastosowanie 32 filtrów o rozmiarze 3×3 oraz `padding="same"` pozwala na zachowanie wymiarowości przestrzennej mapy cech przy jednoczesnej ekstrakcji podstawowych filtrów krawędziowych. Jest to warstwa o kluczowym znaczeniu (*critical path*), ponieważ każdy błąd wagi na tym etapie propaguje się przez całą resztę sieci, co zostało potwierdzone w wynikach eksperymentu.

- **Aktywacja act_0 oraz act_1:** Zastosowano funkcję aktywacji ReLU (*Rectified Linear Unit*), która wprowadza nieliniowość do modelu. Z matematycznego punktu widzenia ReLU eliminuje problem zanikającego gradientu, jednak w implementacjach sprzętowych FPGA jest to operacja niezwykle wydajna, gdyż sprowadza się do prostego porównania wartości z zerem.
- **Warstwa pool_0 i pool_1 (MaxPooling):** Operacja podpróbkiowania (2×2) redukuje przestrzeń cech dwukrotnie w każdym wymiarze. Z punktu widzenia inżynierskiego, *MaxPooling* pełni rolę „kompresora” informacji, ograniczając liczbę operacji mnożenia-dodawania (MAC) w kolejnych etapach sieci, co redukuje zapotrzebowanie na bloki DSP.
- **Warstwa conv_1:** Pogłębienie modelu poprzez zwiększenie liczby filtrów do 64 pozwala na mapowanie cech niższego rzędu (np. krawędzie, plamy) na bardziej złożone struktury (np. kształty obiektów). Wykazano, że ta warstwa jest relatywnie bardziej odporna na kwantyzację niż conv_0, co sugeruje, że redundantność informacji w głębszych warstwach splotowych jest wyższa.

1.4.2 Sekcja klasyfikacyjna (Classification Head)

- **Warstwa flatten:** Przekształca trójwymiarowe mapy cech na wektor jednowymiarowy. Jest to operacja czysto logiczna, niewymagająca zasobów obliczeniowych, lecz wymagająca dużej pamięci wewnątrz FPGA do przechowywania tymczasowego wektora cech.
- **Warstwa dense_0 (Fully Connected):** Warstwa w pełni połączona zawierająca 64 neurony. Działa jako agregator cech wysokopoziomowych. Badania wykazały, że jest to warstwa o średniej wrażliwości – wagi tej warstwy reprezentują relacje między wyekstrahowanymi cechami, dlatego ich kwantyzacja powinna być monitorowana, aby nie doprowadzić do „degradacji decyzji” modelu.
- **Warstwa output_dense oraz softmax:** Ostatni etap sieci, redukujący wektor do 10 wyjść odpowiadających klasom CIFAR-10. Analiza wyników jednoznacznie wskazuje na wysoką odporność tej warstwy na kwantyzację. Wynika to z faktu, że warstwa ta wykonuje operację „ostatecznej decyzji” (przypisanie do klasy), gdzie nawet mindre precyzyjne wagi są wystarczające do zachowania separowalności między klasami. Z perspektywy projektowania sprzętowego, jest to najbezpieczniejsze miejsce do zastosowania agresywnej kwantyzacji (np. 4-bitowej).


2 Metodologia i przebieg eksperymentu badawczego

2.1 Metodologia: Iteracyjna perturbacja wag (Layer-wise Sensitivity Analysis)

W celu zbadania odporności modelu na zmiany precyzji zapisu numerycznego, zastosowano rygorystyczną procedurę badawczą opartą na metodzie *iteracyjnej perturbacji wag*. W przeciwieństwie do globalnej kwantyzacji modelu, gdzie błędy zaokrążeń nakładają się na siebie w sposób nieliniowy i trudny do zinterpretowania, niniejsza metodologia zakłada izolację wpływu kwantyzacji na poszczególne warstwy sieci.

Proces ten oparto na mechanizmie klonowania modelu bazowego `tf.keras.models.clone_model` w każdej iteracji pętli eksperymentalnej. Zastosowanie tego rozwiązania jest kluczowe dla integralności danych naukowych – zapobiega ono kumulacji błędów, w sytuacji gdyby wagi jednej warstwy wpływały na parametry kolejnej w sposób niekontrolowany. Dzięki takiemu podejściu, każdy krok eksperymentu stanowi „punkt startowy” oparty na modelu bazowym FP32, a jedyną zmienną decyzyjną jest precyzja bitowa (od 12 do 4 bitów) w wybranej, testowanej warstwie (`conv_0`, `conv_1`, `dense_0`, `output_dense`).

Zastosowano stres-test modelu, poddając go ewaluacji na zbiorze testowym CIFAR-10 po każdej modyfikacji. Każda z czterech warstw została poddana serii 5 testów (dla konfiguracji bitowych: 4, 6, 8, 10, 12 bitów). Pozwoliło to na wykreślenie krzywych wrażliwości (*sensitivity curves*), które odzwierciedlają tolerancję modelu na błędy kwantyzacji w odniesieniu do jego głębokości i roli w architekturze. Ze względu na stochastyczny charakter inicjalizacji wag oraz podziału zbioru danych, każdy eksperyment kwantyzacji został uruchomiony trzykrotnie w celu uśrednienia wyników. Wynik końcowy przedstawiony w dalszej części pracy stanowi średnią arytmetyczną z przeprowadzonych iteracji, co pozwala wyeliminować wpływ przypadkowych fluktuacji w procesie inferencji i zapewnia statystyczną istotność otrzymanych metryk.



Rysunek 1: Porównanie wpływu izolowanej kwantyzacji wag na Accuracy modelu w zależności od konfiguracji bitowej.

2.2 Analiza wyników eksperymentu (Interpretacja danych)

Analizując wyniki przedstawione na Rysunku 1, można zauważyć wyraźną korelację między głębokością warstwy a jej tolerancją na błąd.

- **Analiza warstwy `conv_0`:** Jest to warstwa o najwyższym stopniu wrażliwości. Wynik 0,4518 przy 4-bitach (z bazowych 0,7073) wskazuje na to, że warstwa ta jest „wąskim gardłem” informacyjnym. Kwantyzacja wag w tej sekcji powoduje zniekształcenie filtrów splotowych, które stają się niezdolne do poprawnej detekcji prymitywnych cech wizualnych, takich jak krawędzie obiektów. Warto zauważyć, że

spadek precyzji z 6 na 4 bity w tej warstwie powoduje drastyczny (niemal liniowy) spadek skuteczności klasyfikacji, co potwierdza, że wagi `conv_0` wymagają wysokiej rozdzielczości bitowej do utrzymania integralności sygnału.

- **Analiza warstwy `conv_1`:** Wyniki wskazują na wyższą odporność (0,6897 przy 4-bitach). Zjawisko to można tłumaczyć faktem, iż warstwy głębsze operują na bardziej abstrakcyjnych reprezentacjach cech. Nawet przy silnej kwantyzacji, filtry te zachowują wystarczającą selektywność, by sklasyfikować obiekt, ponieważ operują na przetworzonym już „skondensowanym” sygnale wejściowym.
- **Analiza warstwy `dense_0`:** Uzyskany wynik 0,6959 dla 4-bitów plasuje tę warstwę w strefie „niskiej wrażliwości”. Wagi warstw w pełni połączonych w tej konfiguracji posiadają nadmiarowość informacyjną. Z matematycznego punktu widzenia oznacza to, że precyzja wag może być zredukowana bez istotnej utraty relacji między cechami, co czyni `dense_0` doskonałym kandydatem do agresywnej kwantyzacji w układach FPGA.
- **Analiza warstwy `output_dense`:** Wynik 0,6899 przy 4-bitach potwierdza końcową odporność klasyfikatora. Warstwa ta wykonuje finalną transformację liniową do przestrzeni klas (*logits*). Nasze badania wykazują, że nawet drastyczna redukcja precyzji w tym miejscu nie narusza struktury decyzji, co sugeruje, że dla poprawnej klasyfikacji wystarczające jest zachowanie relatywnego rozkładu wag, a nie ich bezwzględnej wartości liczbowej.

2.3 Wnioski metodologiczne


Przeprowadzone badania jednoznacznie wskazują na zasadność stosowania analizy warstwowej w procesie projektowania akceleratorów AI. Zrozumienie, że `conv_0` dominuje w profilu wrażliwości modelu, a warstwy `dense` mogą być z powodzeniem „odchudzane” do 4 bitów bez znaczącej degradacji metryk (Precision, Recall), stanowi fundament pod budowę systemów w architekturze *Mixed-Precision*. Zastosowanie tej wiedzy w syntezie HLS pozwoli inżynierowi na zaoszczędzenie znaczącej części zasobów logicznych FPGA poprzez przypisanie szerszych rejestrów tylko tam, gdzie analiza wrażliwości wskazała krytyczny spadek jakości.

3 Analiza wyników eksperymentu

Przeprowadzono wielowymiarową analizę jakościową i ilościową wpływu kwantyzacji wag na metryki wydajności modelu CIFAR-10. Analiza ta jest kluczowa dla zrozumienia dynamiki propagacji błędów w głębokich sieciach neuronowych.

3.1 Analiza profilu wrażliwości (Metryki Accuracy, Precision, Recall, F1-Score)

Analiza profilu wrażliwości wag została przeprowadzona w oparciu o cztery komplementarne metryki. Wykresy (poniżej) przedstawiają degradację parametrów modelu w funkcji szerokości bitowej (od 4 do 12 bitów). Czerwona linia przerywana wyznacza punkt odniesienia (Baseline FP32), co pozwala na bezpośrednią ocenę „kosztu kwantyzacji” dla każdej warstwy.



Rysunek 2: wrażliwości wag modelu CIFAR-10 dla czterech kluczowych metryk wydajności.

Interpretacja danych: Analizując profil dla metryki *Accuracy*, zauważamy, że przy konfiguracji 4-bitowej, warstwa *conv_0* notuje spadek dokładności o blisko 25,5 punktu procentowego względem linii bazowej (z 0,7073 do 0,4518). W tym samym czasie, warstwa *output_dense* wykazuje spadek o jedynie 1,7 punktu procentowego (do 0,6899). Sugeruje to, że warstwy wczesne pełnią funkcję „aktywnych filtrów” – każda zmiana wagi w *conv_0* radykalnie zmieniając kontekst przetwarzanego obrazu, generuje błąd, który jest wzmacniany w kolejnych iteracjach przez warstwę *conv_1*.

Zjawisko to potwierdza hipotezę, że wczesne warstwy filtrują szum, a wprowadzenie „szumu kwantyzacyjnego” w tym miejscu niszczy fundament informacyjny dla całego procesu ekstrakcji cech. W przypadku *output_dense*, model operuje już na wysokopoziomowych deskryptorach, gdzie precyzja wag ma drugorzędne znaczenie dla końcowej decyzji klasyfikacyjnej.

3.2 Analiza macierzy pomyłek (Heatmapy – Analiza klasyfikacyjna)


Aby dogłębnie zbadać naturę błędów wprowadzanych przez kwantyzację, wygenerowano macierze pomyłek. Pozwala to na weryfikację, czy kwantyzacja powoduje losowe błędy, czy też systematyczne pomyłki między określonymi klasami obiektów.

Model Bazowy (FP32) - Pełna precyzja

Rzeczywista klasa	airplane	788	14	48	11	26	9	10	19	42	33
	automobile	34	790	8	4	9	8	13	9	23	102
	bird	70	4	508	23	141	94	74	60	10	16
	cat	28	14	59	373	121	237	91	49	13	15
	deer	23	4	49	25	741	37	42	65	10	4
	dog	17	2	39	86	67	673	32	74	4	6
	frog	5	4	31	27	68	34	817	10	3	1
	horse	18	3	26	11	73	48	5	810	0	6
	ship	93	35	14	10	15	10	9	14	762	38
	truck	40	64	9	9	11	7	10	25	14	811
		airplane	automobile	bird	cat	deer	dog	frog	horse	ship	truck
		Przewidziana klasa									

Rysunek 3: Macierz pomyłek modelu bazowego FP32. Wyraźna dominacja przekątnej potwierdza wysoką skuteczność ekstrakcji cech modelu w warunkach pełnej precyzji.

Analiza modelu bazowego: Model FP32 wykazuje stabilną diagonalną dominację. Klasy takie jak *automobile* czy *ship* są rozpoznawane z wysoką precyzją, co świadczy o tym, że architektura posiada wystarczającą pojemność parametrów do rozróżnienia tych kategorii w standardowej precyzji.



Rysunek 4: Macierze pomyłek dla kwantyzacji 4-bitowej (4,1). Każdy podwykres reprezentuje stan modelu po kwantyzacji wag konkretnej warstwy.

Głęboka analiza 4-bitowa: Macierz pomyłek dla warstwy `conv_0` (4-bit) prezentuje widoczne rozproszenie predykcji poza główną przekątną. Zaobserwowano, że model często błędnie klasyfikuje obiekt „bird” jako „airplane”. Wynika to z faktu, iż wagi warstwy `conv_0` po kwantyzacji do 4-bitów ulegają tak drastycznemu uproszczeniu, że model traci zdolność odróżniania drobnych detali krawędzi (np. rozpiętość skrzydeł ptaka vs metalowy kadłub samolotu).

W przypadku macierzy dla warstwy `dense_0`, model wykazuje mniejszy stopień dezorientacji, jednakże obserwuje się zwiększoną liczbę pomyłek w klasach `cat` oraz `dog`. Oznacza to, że kwantyzacja wag w tej warstwie prowadzi do „złania” reprezentacji obiektów o podobnej morfologii, ponieważ waga 4-bitowa (16 poziomów) nie jest w stanie zakodować subtelnych różnic w cechach głębokich dostarczonych przez sekcję splotową.

3.3 Synteza wyników (Dyskusja nad stabilnością metryk)

Warto zauważyć, że wskaźnik *F1-Score* dla konfiguracji 4-bitowej w warstwie `output_dense` pozostaje niemal niezmienny w porównaniu do modelu bazowego. Dowodzi to tezy o tzw.

redundancji informacyjnej klasyfikatora. Podczas gdy warstwy splotowe muszą wykazywać się wysoką wiernością sygnału (dlatego wymagają min. 8 bitów), warstwa `output_dense` posiada nadmiar wag, co pozwala jej na „nauczenie się” poprawnej klasyfikacji mimo zredukowanej precyzji matematycznej. Wnioskujemy zatem, że kwantyzacja `output_dense` jest najbardziej optymalnym punktem operacyjnym dla projektowania akceleratorów FPGA, umożliwiając drastyczną redukcję szerokości bitowej bez wpływu na użyteczność systemu.

4 Dyskusja i wnioski

4.1 Analiza matematyczna ograniczeń precyzji w warstwach splotowych

Przeprowadzone badania jednoznacznie wskazują, że warstwa `conv_0` stanowi krytyczny komponent architektury modelu w kontekście kwantyzacji wag. Z perspektywy matematycznej, wagi w warstwie splotowej muszą precyzyjnie reagować na gradienty jasności oraz lokalne zmiany tekstury w obrazie wejściowym. Wprowadzenie kwantyzacji do formatu 4-bitowego ogranicza przestrzeń reprezentacji wag do zaledwie 16 poziomów dyskretnych ($2^4 = 16$). Jest to rozdzielczość niewystarczająca do zakodowania wszystkich złożonych filtrów splotowych wymaganych do ekstrakcji cech w zbiorze CIFAR-10.

W warstwach splotowych, gdzie operacja konwolucji (sumowanie iloczynów wag z wartościami pikseli) decyduje o aktywacji neuronów, błąd zaokrąglenia wagi w warstwie wejściowej ulega nieliniowemu wzmocnieniu w procesie propagacji wstecznej i wzdłużnej. Zauważono, iż przy kwantyzacji 4-bitowej, filtry `conv_0` ulegają „zatarciu” – ich zdolność do różnicowania subtelnych gradientów kolorystycznych zostaje utracona, co w konsekwencji prowadzi do wygenerowania map cech o wysokim poziomie szumu. Hipoteza badawcza potwierdza zatem, że warstwy wczesne operują na wysokiej dynamice sygnału, co wymusza stosowanie szerszej reprezentacji bitowej w celu uniknięcia degradacji sygnału wejściowego.

4.2 Redundancja informacyjna a agresywna kwantyzacja

W przeciwieństwie do warstw splotowych, warstwy w pełni połączone (`dense_0`, `output_dense`) charakteryzują się wysokim stopniem redundancji informacyjnej. Analiza rozkładu pomyłek wskazuje na hipotezę, iż wagi w tych warstwach nie wymagają wysokiej precyzji, ponieważ decyzja klasyfikacyjna jest wynikiem agregacji wielu sygnałów wejściowych, co naturalnie wygładza błędy wprowadzone przez kwantyzację.

Zaobserwowano statystycznie istotną odporność warstwy `output_dense` na obniżenie precyzji do 4 bitów. Algorytm przeprowadził dyskretyzację wag w przestrzeni stałoprzecinkowej, odwzorowując charakterystykę pracy bloków DSP układu FPGA, a wyniki wykazały, że model utrzymuje zdolność do poprawnej separacji klas nawet przy zredukowanej szerokości bitowej. Pozwalają to na sformułowanie wniosku, iż w finalnych etapach sieci neuronowej precyzja wag służy jedynie do ustawienia wag decyzyjnych, a nie do modelowania skomplikowanych zależności przestrzennych.

4.3 Strategia Mixed-Precision jako optymalny projekt techniczny

Na podstawie zgromadzonych danych, jako gotowy projekt techniczny dla implementacji na układach FPGA, proponuje się strategię *Mixed-Precision*. Zamiast stosowania jednoli-

tej kwantyzacji dla całej architektury (co prowadzi do utraty celności lub niepotrzebnego zużycia zasobów), sugeruje się następującą hierarchię precyzji:

- **Warstwy ekstrakcji cech (conv_0, conv_1):** Rekomenduje się implementację z precyzją `ap_fixed<12,4>` lub wyższą. Zapewnia to utrzymanie dynamiki sygnału niezbędnej do poprawnej detekcji obiektów w CIFAR-10.
- **Warstwy klasyfikacyjne (dense_0, output_dense):** Rekomenduje się redukcję precyzji do `ap_fixed<6,2>` lub `ap_fixed<4,1>`.

Taka strategia pozwala na znaczącą redukcję zapotrzebowania na jednostki DSP oraz pozwala na efektywniejsze upakowanie logiki wewnątrz układu (redukcja zajętości LUT o szacunkowo 25-40%). Taka architektura systemu pozwala na zachowanie balansu między metryką *Accuracy* a efektywnością energetyczną układu. Jest to podejście bardziej dojrzałe inżyniersko niż naiwna kompresja całego modelu, gdyż uwzględnia specyfikę propagacji błędów w architekturach CNN.